



Universidade Federal
de São João del-Rei

Relatório 02 - Análise Estatística de Dados Escolares

Ailton Machado

01/09/2026

Sumário

1	Objetivo	2
2	Importação dos dados	2
2.1	Verificação do banco de dados	2
3	Preparação das variáveis	2
4	Análise univariada	3
4.1	Número de faltas	3
4.2	Nota média	5
4.3	Turno de estudo	7
4.4	Escolaridade da mãe	8
4.5	Acesso à internet em casa	9
5	Análise bivariada	10
5.1	Acesso à internet e desempenho	10
5.2	Escolaridade da mãe e desempenho	12
5.3	Frequência escolar e desempenho	14
5.4	Perfil dos alunos do turno noturno	18
5.5	Desigualdades educacionais	21
5.6	Análise conjunta de turno e acesso à internet	22
6	Análise multivariada	24
6.1	Interpretação	25
7	Síntese dos resultados	25
8	Recomendações	26
9	Limitações metodológicas	26

1 Objetivo

Realizar uma análise estatística de um banco de dados contendo informações de 1000 alunos de uma escola pública, explorando variáveis relacionadas ao desempenho acadêmico, frequência escolar e características sociofamiliares.

2 Importação dos dados

O banco de dados utilizado contém informações sobre faltas, nota média, turno de estudo, escolaridade da mãe e acesso à internet.

```
dados_alunos <- read.table(
  file = "dados_alunos.csv",
  header = TRUE,
  sep = ";",
  dec = ",",
  stringsAsFactors = FALSE
)
```

2.1 Verificação do banco de dados

```
head(dados_alunos)
```

```
##   faltas nota_media      turno escolaridade_mae acesso_internet
## 1     11      10.0 Vespertino           Médio             Sim
## 2      8       8.3  Matutino      Fundamental             Sim
## 3      9       9.2 Vespertino      Fundamental             Sim
## 4      7       5.8  Matutino           Médio             Sim
## 5      7       8.6 Vespertino      Fundamental             Não
## 6     16       5.3 Vespertino           Médio             Sim
```

```
dim(dados_alunos)
```

```
## [1] 1000    5
```

```
str(dados_alunos)
```

```
## 'data.frame':    1000 obs. of  5 variables:
##  $ faltas      : int  11 8 9 7 7 16 12 7 8 7 ...
##  $ nota_media  : num  10 8.3 9.2 5.8 8.6 5.3 7.8 6.7 5.5 7.3 ...
##  $ turno      : chr  "Vespertino" "Matutino" "Vespertino" "Matutino" ...
##  $ escolaridade_mae: chr  "Médio" "Fundamental" "Fundamental" "Médio" ...
##  $ acesso_internet: chr  "Sim" "Sim" "Sim" "Sim" ...
```

3 Preparação das variáveis

As variáveis qualitativas foram convertidas para fatores, respeitando a natureza nominal ou ordinal de cada uma.

```

dados_alunos$turno <- factor(dados_alunos$turno)

dados_alunos$acesso_internet <- factor(dados_alunos$acesso_internet)

dados_alunos$escolaridade_mae <- factor(
  dados_alunos$escolaridade_mae,
  levels = c("Fundamental", "Médio", "Superior"),
  ordered = TRUE
)

str(dados_alunos)

## 'data.frame':    1000 obs. of  5 variables:
##  $ faltas          : int   11 8 9 7 7 16 12 7 8 7 ...
##  $ nota_media      : num   10 8.3 9.2 5.8 8.6 5.3 7.8 6.7 5.5 7.3 ...
##  $ turno           : Factor w/ 3 levels "Matutino","Noturno",...: 3 1 3 1 3 3 1 3 1 2 ...
##  $ escolaridade_mae: Ord.factor w/ 3 levels "Fundamental"<..: 2 1 1 2 1 2 1 1 2 2 ...
##  $ acesso_internet : Factor w/ 2 levels "Não","Sim": 2 2 2 2 1 2 2 1 2 2 ...

```

4 Análise univariada

Nesta etapa, cada variável do banco de dados será analisada individualmente, utilizando medidas-resumo e representações gráficas adequadas ao seu tipo.

4.1 Número de faltas

A variável `faltas` é quantitativa discreta e representa o número de ausências de cada aluno ao longo do período considerado.

```

summary(dados_alunos$faltas)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.000   6.000   8.000   8.013  10.000  19.000

mean(dados_alunos$faltas)

## [1] 8.013

median(dados_alunos$faltas)

## [1] 8

sd(dados_alunos$faltas)

## [1] 2.79869

```


Para visualizar a distribuição do número de faltas, foi construído um histograma.

```

hist(
  dados_alunos$faltas,
  main = "Distribuição do número de faltas",
  xlab = "Número de faltas"
)

```


Distribuição do número de faltas



Também foi utilizado um boxplot para observar a distribuição e a possível presença de valores atípicos.

```
boxplot(  
  dados_alunos$faltas,  
  main = "Distribuição do número de faltas",  
  ylab = "Número de faltas"  
)
```

Distribuição do número de faltas



4.1.1 Interpretação

O número médio de faltas dos alunos foi de aproximadamente **8,01**, valor muito próximo da mediana, que foi igual a **8**. Isso indica que o número típico de faltas dos estudantes está em torno de oito ausências.

O primeiro quartil foi igual a **6** e o terceiro quartil igual a **10**, indicando que aproximadamente 50% dos alunos apresentaram entre 6 e 10 faltas.

O desvio-padrão foi de aproximadamente **2,80**, mostrando uma dispersão moderada em torno da média.

O histograma mostra maior concentração dos alunos nas faixas intermediárias de faltas. O boxplot indica ainda a presença de alguns valores elevados que podem ser considerados atípicos, próximos de 17 e 19 faltas.

4.2 Nota média

A variável `nota_media` é quantitativa contínua e representa o desempenho acadêmico médio de cada aluno.

```
summary(dados_alunos$nota_media)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max. \n##    0.500   5.200   6.500   6.444   7.700   10.000
```

```
mean(dados_alunos$nota_media)
```

```
## [1] 6.4438
```

```
median(dados_alunos$nota_media)
```


```
## [1] 6.5
```

```
sd(dados_alunos$nota_media)
```

```
## [1] 1.882463
```

Para visualizar a distribuição das notas médias, foi construído um histograma.


```
hist(  
  dados_alunos$nota_media,  
  main = "Distribuição das notas médias",  
  xlab = "Nota média"  
)
```



Também foi construído um boxplot para analisar a distribuição das notas e identificar possíveis valores atípicos.

```
boxplot(  
  dados_alunos$nota_media,  
  main = "Distribuição das notas médias",  
  ylab = "Nota média"  
)
```

Distribuição das notas médias



4.2.1 Interpretação

A nota média dos alunos foi de aproximadamente **6,44**, enquanto a mediana foi igual a **6,5**. A proximidade entre essas duas medidas indica que o desempenho dos estudantes está concentrado em torno desse valor.

O primeiro quartil foi **5,2** e o terceiro quartil **7,7**, indicando que aproximadamente 50% dos alunos apresentaram notas entre 5,2 e 7,7.

O desvio-padrão foi de aproximadamente **1,88**, mostrando uma dispersão considerável das notas em relação à média.

O histograma mostra maior concentração das notas na região entre aproximadamente 5 e 8 pontos. O boxplot evidencia ainda alguns valores baixos considerados atípicos, próximos de 1 ponto ou inferiores. Não foram observados valores atípicos elevados.

4.3 Turno de estudo

A variável `turno` é qualitativa nominal e possui as categorias Matutino, Vespertino e Noturno.

```
table(dados_alunos$turno)
```


```
##  
##   Matutino   Noturno Vespertino  
##       451       204       345
```

```
round(prop.table(table(dados_alunos$turno)) * 100, 2)
```

```
##  
##   Matutino   Noturno Vespertino
```

```
##          45.1          20.4          34.5
```

```
barplot(
  table(dados_alunos$turno),
  main = "Distribuição dos alunos por turno",
  xlab = "Turno",
  ylab = "Número de alunos"
)
```



4.3.1 Interpretação

Dos 1000 alunos analisados, 451 (45,1%) estudam no turno Matutino, 345 (34,5%) no Vespertino e 204 (20,4%) no Noturno. Dessa forma, o turno Matutino apresenta a maior participação no banco de dados, enquanto o Noturno possui o menor número de alunos.

4.4 Escolaridade da mãe

A variável `escolaridade_mae` é qualitativa ordinal, pois suas categorias apresentam uma ordem natural: Fundamental, Médio e Superior.

```
table(dados_alunos$escolaridade_mae)
```

```
##
## Fundamental      Médio      Superior
##           391          459          150
```


```
round(prop.table(table(dados_alunos$escolaridade_mae)) * 100, 2)
```

```
##
```



```
## Fundamental      Médio      Superior
##           39.1      45.9      15.0
```

```
barplot(
  table(dados_alunos$escolaridade_mae),
  main = "Escolaridade da mãe",
  xlab = "Escolaridade",
  ylab = "Número de alunos"
)
```



4.4.1 Interpretação

Em relação à escolaridade da mãe, 459 alunos (45,9%) possuem mães com Ensino Médio, 391 (39,1%) com Ensino Fundamental e 150 (15,0%) com Ensino Superior. Portanto, a categoria mais frequente é o Ensino Médio, enquanto o Ensino Superior apresenta a menor frequência.

4.5 Acesso à internet em casa

A variável `acesso_internet` é qualitativa nominal dicotômica, com as categorias Sim e Não.


```
table(dados_alunos$acesso_internet)
```

```
##
## Não Sim
## 297 703
```

```
round(prop.table(table(dados_alunos$acesso_internet)) * 100, 2)
```

```
##
```

```
## Não Sim
## 29.7 70.3
barplot(
  table(dados_alunos$acesso_internet),
  main = "Acesso à internet em casa",
  xlab = "Acesso à internet",
  ylab = "Número de alunos"
)
```



4.5.1 Interpretação

A maioria dos alunos possui acesso à internet em casa. Dos 1000 estudantes, 703 (70,3%) declararam possuir acesso, enquanto 297 (29,7%) não possuem. Assim, aproximadamente sete em cada dez alunos do banco têm acesso à internet em casa.

5 Análise bivariada

Nesta etapa são investigadas relações entre pares de variáveis, buscando identificar possíveis associações entre características dos alunos e seu desempenho acadêmico.

5.1 Acesso à internet e desempenho


Inicialmente, foram calculadas as notas médias dos alunos segundo a disponibilidade de acesso à internet em casa.

```
aggregate(
  nota_media ~ acesso_internet,
  data = dados_alunos,
  FUN = mean
)
```

```
##  acesso_internet nota_media
## 1              Não  6.481818
## 2              Sim  6.427738
```

Para comparar visualmente a distribuição das notas entre os dois grupos, foi construído um boxplot.

```
boxplot(
  nota_media ~ acesso_internet,
  data = dados_alunos,
  main = "Nota média segundo o acesso à internet",
  xlab = "Acesso à internet em casa",
  ylab = "Nota média"
)
```



Para verificar se existe diferença estatisticamente significativa entre as médias dos dois grupos, foi aplicado o teste t de Welch.

```
t.test(
  nota_media ~ acesso_internet,
  data = dados_alunos
)
```

```
##
## Welch Two Sample t-test
##
## data: nota_media by acesso_internet
## t = 0.41236, df = 549.34, p-value = 0.6802
## alternative hypothesis: true difference in means between group Não and group Sim is not equal to 0
## 95 percent confidence interval:
## -0.2035329 0.3116928
## sample estimates:
## mean in group Não mean in group Sim
## 6.481818 6.427738
```

5.1.1 Interpretação

Os alunos sem acesso à internet apresentaram nota média de aproximadamente **6,48**, enquanto os alunos com acesso à internet apresentaram média de aproximadamente **6,43**.

Embora exista uma pequena diferença entre as médias, o teste t de Welch apresentou **p = 0,6802**, valor superior ao nível de significância de 5% (0,05). Portanto, não há evidências estatísticas suficientes para concluir que exista diferença significativa entre as notas médias dos alunos com e sem acesso à internet.

Além disso, o intervalo de confiança de 95% para a diferença entre as médias inclui o valor zero, reforçando a conclusão de que a diferença observada pode ser atribuída à variabilidade amostral.

Assim, neste conjunto de dados, **não foi encontrada evidência de que alunos com acesso à internet em casa apresentem notas médias significativamente maiores.**

5.2 Escolaridade da mãe e desempenho

A segunda questão investigativa busca verificar como a escolaridade da mãe se relaciona com o desempenho acadêmico dos alunos.

Inicialmente, foram calculadas as notas médias dos estudantes para cada nível de escolaridade materna.


```
aggregate(
  nota_media ~ escolaridade_mae,
  data = dados_alunos,
  FUN = mean
)
```

```
## escolaridade_mae nota_media
## 1 Fundamental 6.328389
## 2 Médio 6.553813
## 3 Superior 6.408000
```

Para comparar visualmente a distribuição das notas entre os três níveis de escolaridade da mãe, foi construído um boxplot.

```
boxplot(
  nota_media ~ escolaridade_mae,
  data = dados_alunos,
  main = "Nota média segundo a escolaridade da mãe",
  xlab = "Escolaridade da mãe",
  ylab = "Nota média"
)
```

Nota média segundo a escolaridade da mãe



Como existem três grupos de escolaridade — Fundamental, Médio e Superior — foi realizada uma análise de variância (ANOVA) para verificar se há diferença estatisticamente significativa entre as médias.

```
modelo_escolaridade <- aov(  
  nota_media ~ escolaridade_mae,  
  data = dados_alunos  
)  
  
summary(modelo_escolaridade)
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)  
## escolaridade_mae  2     11    5.478   1.547  0.213  
## Residuals      997    3529    3.540
```

5.2.1 Interpretação

Os alunos cujas mães possuem Ensino Fundamental apresentaram nota média de aproximadamente **6,33**. Entre os alunos cujas mães possuem Ensino Médio, a nota média foi aproximadamente **6,55**, enquanto aqueles cujas mães possuem Ensino Superior apresentaram média de aproximadamente **6,41**.

Descritivamente, o grupo correspondente ao Ensino Médio apresentou a maior média, seguido pelo Ensino Superior e pelo Ensino Fundamental. Entretanto, as diferenças observadas entre os três grupos são pequenas.

A análise de variância apresentou valor de **F aproximadamente igual a 1,55** e **p aproximadamente igual a 0,213**. Como o valor de p é superior ao nível de significância de 5% (0,05), não há evidências estatísticas suficientes para concluir que as notas médias sejam diferentes entre os níveis de escolaridade materna.

Portanto, neste conjunto de dados, **não foi encontrada evidência estatisticamente significativa de que**

a escolaridade da mãe esteja associada a diferenças no desempenho médio dos alunos. Embora tenham sido observadas pequenas diferenças nas médias, elas podem ser explicadas pela variabilidade dos dados.

5.3 Frequência escolar e desempenho

A terceira questão investigativa busca analisar a relação entre o número de faltas e a nota média dos alunos. Inicialmente, foi calculado o coeficiente de correlação de Pearson entre as duas variáveis.

```
cor(
  dados_alunos$faltas,
  dados_alunos$nota_media
)
```

```
## [1] -0.01006418
```

Para verificar também a significância estatística da correlação, foi realizado o teste de correlação de Pearson.


```
cor.test(
  dados_alunos$faltas,
  dados_alunos$nota_media,
  method = "pearson"
)
```

```
##
## Pearson's product-moment correlation
##
## data: dados_alunos$faltas and dados_alunos$nota_media
## t = -0.31796, df = 998, p-value = 0.7506
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.07201234 0.05196132
## sample estimates:
## cor
## -0.01006418
```

Para visualizar a relação entre as variáveis, foi construído um gráfico de dispersão.

```
plot(
  dados_alunos$faltas,
  dados_alunos$nota_media,
  main = "Relação entre número de faltas e nota média",
  xlab = "Número de faltas",
  ylab = "Nota média",
  pch = 19
)
```

Relação entre número de faltas e nota média



Também foi ajustado um modelo de regressão linear simples, considerando a nota média como variável resposta e o número de faltas como variável explicativa.

```
modelo_faltas <- lm(
  nota_media ~ faltas,
  data = dados_alunos
)
```

```
summary(modelo_faltas)
```


```
##
## Call:
## lm(formula = nota_media ~ faltas, data = dados_alunos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.9507 -1.2439  0.0392  1.2832  3.6035
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.498043   0.180697  35.961  <2e-16 ***
## faltas      -0.006769   0.021290  -0.318    0.751
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.883 on 998 degrees of freedom
## Multiple R-squared:  0.0001013, Adjusted R-squared:  -0.0009006
```

```
## F-statistic: 0.1011 on 1 and 998 DF, p-value: 0.7506
```

A reta de regressão foi acrescentada ao gráfico de dispersão.

```
plot(
  dados_alunos$faltas,
  dados_alunos$nota_media,
  main = "Faltas e desempenho acadêmico",
  xlab = "Número de faltas",
  ylab = "Nota média",
  pch = 19
)

abline(
  modelo_faltas,
  lwd = 2
)
```



5.3.1 Investigação de um possível ponto crítico

Para investigar se existe alguma faixa de faltas associada a uma redução mais acentuada no desempenho, os alunos foram agrupados segundo o número de ausências.

```
dados_alunos$faixa_faltas <- cut(
  dados_alunos$faltas,
  breaks = c(-1, 5, 10, 15, 20, 25, 30),
  labels = c(
    "0 a 5",

```



```

    "6 a 10",
    "11 a 15",
    "16 a 20",
    "21 a 25",
    "26 a 30"
  )
)

table(dados_alunos$faixa_faltas)

```

```

##
##   0 a 5  6 a 10 11 a 15 16 a 20 21 a 25 26 a 30
##    179    645    167     9      0      0

```

Em seguida, foram calculadas as notas médias para cada faixa de faltas.

```

aggregate(
  nota_media ~ faixa_faltas,
  data = dados_alunos,
  FUN = mean
)

```

```

##   faixa_faltas nota_media
## 1      0 a 5    6.368156
## 2      6 a 10    6.472093
## 3     11 a 15    6.461078
## 4     16 a 20    5.600000

```

5.3.2 Interpretação

O coeficiente de correlação de Pearson entre o número de faltas e a nota média foi de aproximadamente **-0,01**, indicando uma correlação linear praticamente nula entre as duas variáveis.

O teste de correlação apresentou **p aproximadamente igual a 0,75**, valor bastante superior ao nível de significância de 5% (0,05). Portanto, não há evidências estatísticas de uma relação linear significativa entre o número de faltas e a nota média neste conjunto de dados.

O modelo de regressão linear também apresentou uma inclinação muito próxima de zero. O coeficiente associado ao número de faltas foi de aproximadamente **-0,0068**, indicando que o aumento de uma falta estaria associado, em média, a uma redução de apenas cerca de 0,007 ponto na nota. Além disso, o modelo apresentou um coeficiente de determinação muito próximo de zero, mostrando que o número de faltas praticamente não explica a variabilidade das notas neste banco de dados.

A análise por faixas mostrou aproximadamente as seguintes médias:

- de 0 a 5 faltas: **6,37**;
- de 6 a 10 faltas: **6,47**;
- de 11 a 15 faltas: **6,46**;
- de 16 a 20 faltas: **5,60**.

Embora a última faixa apresente uma nota média menor, ela contém apenas **9 alunos**, enquanto as demais faixas possuem um número muito maior de observações. Dessa forma, essa redução deve ser interpretada com cautela.

Portanto, **não foi possível identificar, com os dados disponíveis, um ponto crítico bem definido a partir do qual o aumento das faltas comprometa severamente o desempenho acadêmico**. A redução observada entre os alunos com 16 a 20 faltas é interessante do ponto de vista descritivo, mas o

pequeno número de estudantes nessa faixa não permite tratá-la como evidência conclusiva de um limiar de faltas.

5.4 Perfil dos alunos do turno noturno

A quarta questão investigativa busca verificar se os alunos do turno noturno apresentam maior número de faltas e como seu desempenho acadêmico se compara ao dos estudantes dos turnos Matutino e Vespertino.

Inicialmente, foram calculadas as médias de faltas em cada turno.


```
aggregate(  
  faltas ~ turno,  
  data = dados_alunos,  
  FUN = mean  
)
```

```
##      turno  faltas  
## 1  Matutino 8.033259  
## 2   Noturno 7.946078  
## 3 Vespertino 8.026087
```

Para comparar visualmente a distribuição das faltas entre os turnos, foi construído um boxplot.

```
boxplot(  
  faltas ~ turno,  
  data = dados_alunos,  
  main = "Número de faltas segundo o turno",  
  xlab = "Turno",  
  ylab = "Número de faltas"  
)
```

Número de faltas segundo o turno



Para verificar se existem diferenças estatisticamente significativas entre as médias de faltas dos três turnos, foi realizada uma análise de variância (ANOVA).

```
modelo_faltas_turno <- aov(  
  faltas ~ turno,  
  data = dados_alunos  
)  
  
summary(modelo_faltas_turno)
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)  
## turno      2      1   0.579   0.074  0.929  
## Residuals 997  7824   7.847
```

Em seguida, foram calculadas as notas médias dos alunos de cada turno.


```
aggregate(  
  nota_media ~ turno,  
  data = dados_alunos,  
  FUN = mean  
)  
  
##      turno nota_media  
## 1  Matutino  6.461419  
## 2   Noturno  6.584804  
## 3 Vespertino  6.337391
```

Para visualizar as diferenças no desempenho acadêmico entre os turnos, foi construído um boxplot.

```

boxplot(
  nota_media ~ turno,
  data = dados_alunos,
  main = "Nota média segundo o turno",
  xlab = "Turno",
  ylab = "Nota média"
)

```



Também foi realizada uma análise de variância para verificar se as diferenças observadas entre as notas médias dos três turnos são estatisticamente significativas.

```

modelo_nota_turno <- aov(
  nota_media ~ turno,
  data = dados_alunos
)

summary(modelo_nota_turno)

```

```

##           Df Sum Sq Mean Sq F value Pr(>F)
## turno      2      8    4.051   1.144  0.319
## Residuals 997   3532    3.543

```

5.4.1 Interpretação

O número médio de faltas foi de aproximadamente **8,03** no turno Matutino, **7,95** no Noturno e **8,03** no Vespertino.

Portanto, descritivamente, os alunos do turno Noturno não apresentaram maior número de faltas. Na

realidade, sua média de faltas foi ligeiramente menor que a observada nos outros dois turnos.

A análise de variância para o número de faltas apresentou **F aproximadamente igual a 0,074** e **p aproximadamente igual a 0,929**. Como o valor de p é muito superior a 0,05, não há evidências estatísticas de diferença entre o número médio de faltas dos três turnos.

Em relação ao desempenho acadêmico, as notas médias foram aproximadamente:

- Matutino: **6,46**;
- Noturno: **6,58**;
- Vespertino: **6,34**.

O turno Noturno apresentou, descritivamente, a maior nota média entre os três grupos. Entretanto, a análise de variância apresentou **F aproximadamente igual a 1,14** e **p aproximadamente igual a 0,319**.

Como o valor de p também é superior ao nível de significância de 5%, não há evidências estatísticas suficientes para afirmar que o desempenho médio seja diferente entre os turnos.

Assim, neste conjunto de dados, **os alunos do turno Noturno não apresentam mais faltas que os demais e também não foi identificada diferença estatisticamente significativa no desempenho acadêmico entre os três turnos**.

5.5 Desigualdades educacionais

A quinta questão investigativa busca verificar se características sociofamiliares, especificamente a escolaridade da mãe e o acesso à internet em casa, ajudam a explicar parte da variabilidade observada nas notas dos alunos.

Para isso, foi ajustado um modelo de regressão linear múltipla, considerando a nota média como variável resposta e a escolaridade da mãe e o acesso à internet como variáveis explicativas.

```
modelo_sociofamiliar <- lm(
  nota_media ~ escolaridade_mae + acesso_internet,
  data = dados_alunos
)

summary(modelo_sociofamiliar)

##
## Call:
## lm(formula = nota_media ~ escolaridade_mae + acesso_internet,
##     data = dados_alunos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.0363 -1.2363 -0.0047  1.3269  3.6917
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      6.47485    0.11236   57.626  <2e-16 ***
## escolaridade_mae.L  0.05459    0.12787    0.427   0.670
## escolaridade_mae.Q -0.15462    0.10310   -1.500   0.134
## acesso_internetSim -0.06478    0.13049   -0.496   0.620
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.882 on 996 degrees of freedom
## Multiple R-squared:  0.003341,    Adjusted R-squared:  0.0003393
```

```
## F-statistic: 1.113 on 3 and 996 DF, p-value: 0.3428
```

5.5.1 Interpretação

O modelo de regressão múltipla permite analisar conjuntamente a associação entre escolaridade materna, acesso à internet e desempenho acadêmico.

Os coeficientes estimados para as variáveis sociofamiliares foram pequenos e os respectivos valores de p ficaram acima do nível de significância de 5%, indicando ausência de evidências estatísticas suficientes para afirmar que essas variáveis estejam associadas de forma significativa à nota média neste conjunto de dados.

Além disso, o coeficiente de determinação do modelo, representado pelo R^2 , foi muito próximo de zero. Isso significa que a escolaridade da mãe e o acesso à internet explicam apenas uma parcela muito pequena da variabilidade observada nas notas dos estudantes.

Portanto, neste banco de dados, **as variáveis sociofamiliares analisadas não explicam de forma relevante a variação do desempenho acadêmico dos alunos**. Isso não significa que essas características não sejam importantes em contextos educacionais reais, mas apenas que, neste conjunto de dados específico, não foi identificada uma associação estatisticamente significativa.

5.6 Análise conjunta de turno e acesso à internet

A sexta questão investigativa busca identificar possíveis padrões no desempenho acadêmico quando são consideradas conjuntamente as variáveis turno de estudo e acesso à internet em casa.

Inicialmente, foram calculadas as notas médias para cada combinação entre turno e acesso à internet.

```
aggregate(  
  nota_media ~ turno + acesso_internet,  
  data = dados_alunos,  
  FUN = mean  
)  
  
##      turno acesso_internet nota_media  
## 1   Matutino           Não   6.541353  
## 2    Noturno           Não   6.861404  
## 3 Vespertino           Não   6.205607  
## 4   Matutino           Sim   6.427987  
## 5    Noturno           Sim   6.477551  
## 6 Vespertino           Sim   6.396639
```

Também foi verificado o número de alunos em cada combinação de categorias.

```
table(  
  dados_alunos$turno,  
  dados_alunos$acesso_internet  
)  
  
##  
##           Não Sim  
## Matutino  133 318  
## Noturno    57 147  
## Vespertino 107 238
```


Para facilitar a visualização dos possíveis padrões, foi construído um gráfico de interação.

```
interaction.plot(  
  x.factor = dados_alunos$turno,  
  trace.factor = dados_alunos$acesso_internet,
```

```

response = dados_alunos$nota_media,
xlab = "Turno",
ylab = "Nota média",
trace.label = "Acesso à internet"
)

```



Por fim, foi utilizada uma análise de variância de dois fatores, incluindo a interação entre turno e acesso à internet.

```

modelo_interacao <- aov(
  nota_media ~ turno * acesso_internet,
  data = dados_alunos
)

```

```
summary(modelo_interacao)
```

```

##              Df Sum Sq Mean Sq F value Pr(>F)
## turno          2      8  4.051    1.143  0.319
## acesso_internet  1      1  0.725    0.205  0.651
## turno:acesso_internet  2      9  4.613    1.302  0.272
## Residuals     994    3522   3.543

```

5.6.1 Interpretação

As notas médias encontradas para cada combinação foram aproximadamente:

- Matutino sem internet: **6,54**;
- Matutino com internet: **6,43**;

- Noturno sem internet: **6,86**;
- Noturno com internet: **6,48**;
- Vespertino sem internet: **6,21**;
- Vespertino com internet: **6,40**.

Descritivamente, o grupo com maior nota média foi formado pelos alunos do turno Noturno sem acesso à internet, com média aproximada de **6,86**. A menor média foi observada entre os alunos do turno Vespertino sem acesso à internet, com aproximadamente **6,21**.

Entretanto, a análise de variância de dois fatores não apresentou evidência estatisticamente significativa para o efeito do turno, para o acesso à internet ou para a interação entre essas duas variáveis.

Em particular, o efeito de interação entre turno e acesso à internet apresentou valor de **p aproximadamente igual a 0,27**, superior ao nível de significância de 5%.

Assim, embora existam pequenas diferenças descritivas entre as seis combinações analisadas, **não foi identificado um padrão estatisticamente significativo indicando que o efeito do acesso à internet sobre o desempenho dependa do turno de estudo**.

6 Análise multivariada

Nesta etapa, as principais variáveis do banco de dados são consideradas simultaneamente, buscando verificar quais delas apresentam associação com o desempenho acadêmico quando as demais são mantidas no modelo.

Foi ajustado um modelo de regressão linear múltipla, considerando a nota média como variável resposta e o número de faltas, o turno, a escolaridade da mãe e o acesso à internet como variáveis explicativas.

```
modelo_completo <- lm(
  nota_media ~ faltas + turno + escolaridade_mae + acesso_internet,
  data = dados_alunos
)

summary(modelo_completo)
```

```
##
## Call:
## lm(formula = nota_media ~ faltas + turno + escolaridade_mae +
##     acesso_internet, data = dados_alunos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.0557 -1.2593  0.0225  1.3112  3.8040
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    6.534384   0.209824  31.142  <2e-16 ***
## faltas        -0.004847   0.021347  -0.227   0.820
## turnoNoturno    0.130076   0.159518   0.815   0.415
## turnoVespertino -0.123596   0.134681  -0.918   0.359
## escolaridade_mae.L 0.067139   0.128508   0.522   0.601
## escolaridade_mae.Q -0.150025   0.103194  -1.454   0.146
## acesso_internetSim -0.067265   0.130863  -0.514   0.607
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.883 on 993 degrees of freedom
## Multiple R-squared:  0.00578,    Adjusted R-squared:  -0.0002277
```


F-statistic: 0.9621 on 6 and 993 DF, p-value: 0.4497

6.1 Interpretação

A análise multivariada permitiu avaliar simultaneamente a associação entre número de faltas, turno de estudo, escolaridade da mãe, acesso à internet e desempenho acadêmico.

Nenhuma das variáveis incluídas no modelo apresentou associação estatisticamente significativa com a nota média ao nível de significância de 5%. Os valores de p foram superiores a 0,05 para número de faltas, turno de estudo, escolaridade materna e acesso à internet.

O coeficiente de determinação foi $R^2 = 0,0058$, indicando que o conjunto de variáveis analisadas explica aproximadamente **0,58% da variabilidade observada nas notas médias**. Portanto, a capacidade explicativa do modelo é muito pequena.

O R^2 ajustado apresentou valor ligeiramente negativo, aproximadamente **-0,0002**. Isso indica que, após considerar o número de variáveis incluídas no modelo, seu poder explicativo não é superior de maneira relevante ao de um modelo que utilizasse apenas a média geral das notas.

Além disso, o teste global do modelo apresentou $F = 0,9621$ e $p = 0,4497$. Como esse valor de p é superior a 0,05, o modelo como um todo não apresentou significância estatística.

Dessa forma, neste conjunto de dados, **não foram encontradas evidências de que faltas, turno de estudo, escolaridade da mãe e acesso à internet, consideradas conjuntamente, expliquem de maneira estatisticamente significativa o desempenho acadêmico dos alunos**.

7 Síntese dos resultados

A análise do banco de dados permitiu descrever o perfil dos 1000 alunos e investigar possíveis relações entre desempenho acadêmico, frequência escolar, turno de estudo e características sociofamiliares.

Na análise univariada, o número médio de faltas foi de aproximadamente **8,01**, enquanto a nota média dos alunos foi de aproximadamente **6,44**. A maior parte dos estudantes estava matriculada no turno Matutino, correspondendo a **45,1%** da amostra. Em relação à escolaridade materna, a categoria mais frequente foi Ensino Médio, com **45,9%**. Além disso, **70,3%** dos estudantes possuíam acesso à internet em casa.

Nas análises bivariadas, foram obtidos os seguintes resultados principais:

- não foi encontrada diferença estatisticamente significativa entre as notas dos alunos com e sem acesso à internet em casa;
- não foi encontrada diferença estatisticamente significativa entre as notas médias dos alunos segundo a escolaridade da mãe;
- a correlação entre número de faltas e nota média foi praticamente nula e não significativa;
- não foi possível identificar um ponto crítico bem definido a partir do qual o número de faltas compromettesse severamente o desempenho;
- os alunos do turno Noturno não apresentaram maior média de faltas que os estudantes dos demais turnos;
- não foram encontradas diferenças estatisticamente significativas nas notas médias entre os turnos;
- não foi identificada interação estatisticamente significativa entre turno de estudo e acesso à internet.

Na análise das características sociofamiliares, escolaridade da mãe e acesso à internet explicaram apenas uma parcela muito pequena da variabilidade das notas.

Finalmente, no modelo multivariado, o conjunto formado por número de faltas, turno, escolaridade da mãe e acesso à internet explicou aproximadamente **0,58% da variabilidade das notas médias**. O modelo global não apresentou significância estatística.

Assim, para este conjunto de dados, as variáveis consideradas não se mostraram suficientes para explicar de maneira relevante as diferenças observadas no desempenho acadêmico.

8 Recomendações

Com base nos resultados obtidos, recomenda-se cautela ao utilizar isoladamente variáveis como número de faltas, turno, escolaridade materna ou acesso à internet para explicar o desempenho acadêmico dos estudantes.

Como essas características apresentaram baixa capacidade explicativa neste banco de dados, análises futuras poderiam incorporar outras variáveis potencialmente relacionadas ao rendimento escolar, tais como:

- hábitos e tempo dedicado aos estudos;
- participação e envolvimento nas atividades escolares;
- condições de trabalho dos estudantes;
- renda familiar;
- estrutura e recursos disponíveis na escola;
- histórico de desempenho acadêmico;
- fatores motivacionais e socioemocionais;
- acompanhamento familiar.

A utilização de um conjunto mais amplo de informações poderá permitir uma compreensão mais completa dos fatores associados ao desempenho dos alunos.

9 Limitações metodológicas

Os resultados deste relatório devem ser interpretados considerando algumas limitações.

Em primeiro lugar, o banco de dados utilizado foi construído para **simular uma situação de pesquisa em uma escola pública brasileira**, com finalidade pedagógica. Portanto, os resultados obtidos não devem ser generalizados diretamente para todos os estudantes ou escolas públicas brasileiras.

Além disso, foram consideradas somente cinco variáveis, o que limita a capacidade de representar toda a complexidade do processo educacional.

Outra limitação importante é que as análises realizadas identificam principalmente **associações estatísticas**. Mesmo quando uma relação estatisticamente significativa é encontrada, isso não permite concluir automaticamente que uma variável seja causa da outra.

Também devem ser consideradas as diferenças no número de observações entre alguns grupos. Na análise das faixas de faltas, por exemplo, o grupo de alunos com 16 a 20 faltas apresentou apenas nove estudantes, exigindo cautela na interpretação da redução observada na nota média desse grupo.

Por fim, a ausência de significância estatística não significa necessariamente que uma determinada característica seja irrelevante em contextos educacionais reais. Significa apenas que, neste banco de dados e com as análises utilizadas, não foram encontradas evidências estatísticas suficientes para demonstrar determinada associação.

10 Sugestões para pesquisas futuras

Pesquisas futuras poderiam utilizar dados observados em escolas reais e incluir um número maior de variáveis relacionadas às características individuais, familiares e escolares dos estudantes.

Também seria interessante acompanhar os mesmos alunos ao longo do tempo, permitindo investigar como alterações na frequência, nas condições socioeconômicas e no acesso a recursos educacionais se relacionam com a evolução do desempenho.

Outra possibilidade seria ampliar o tamanho dos grupos menos representados e utilizar métodos estatísticos adicionais para investigar relações não lineares e possíveis interações entre diferentes fatores.

11 Considerações finais

A realização deste relatório permitiu aplicar, de maneira prática, diferentes ferramentas de análise estatística a um conjunto de dados contextualizado no ambiente escolar.

Foram realizadas análises univariadas, bivariadas e multivariadas, utilizando medidas descritivas, representações gráficas, testes de hipóteses, correlação, análise de variância e modelos de regressão.

Os resultados mostraram que, neste conjunto de dados, nenhuma das variáveis investigadas apresentou forte capacidade de explicar o desempenho acadêmico dos alunos. Esse resultado evidencia a importância de evitar conclusões baseadas apenas em diferenças observadas descritivamente e de utilizar procedimentos estatísticos para avaliar se tais diferenças possuem evidência suficiente.

Dessa forma, o trabalho possibilitou não apenas descrever os dados, mas também exercitar a interpretação crítica dos resultados e compreender algumas das possibilidades e limitações da análise estatística aplicada a problemas educacionais.